

Análisis de Diagnóstico de Cáncer

Daniel Antonio Guzmán Martínez
Dylan Robles Fill

May 14, 2026

Modelo de Regresión Logística

- ▶ La regresión logística es un modelo estadístico para **predecir la probabilidad de un evento binario** (por ejemplo: maligno o benigno).
- ▶ En lugar de predecir valores continuos como en la regresión lineal, predice **probabilidades entre 0 y 1**.
- ▶ Es ampliamente usado en medicina, ciencias sociales y economía para **clasificación de eventos discretos**.

Ecuación de la Regresión Logística

- ▶ El modelo predice la probabilidad $P(Y = 1)$ usando la función sigmoide:

$$P(Y = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_n X_n)}}$$

- ▶ β_0 = intercepto, β_i = coeficiente de la variable X_i
- ▶ La salida $P(Y = 1)$ se interpreta como la probabilidad de que el evento ocurra.
- ▶ Para obtener odds ratio:

$$\text{Odds Ratio} = e^{\beta_i}$$

que indica cómo cambia la probabilidad relativa con un aumento de 1 unidad en X_i .

Uso de la Regresión Logística

- ▶ Clasificación binaria: benigno/maligno, aprobado/reprobado, sí/no, etc.
- ▶ Evaluación de desempeño:
 - ▶ Matriz de confusión
 - ▶ Accuracy, Precision, Recall, F1-score
 - ▶ Curva ROC y AUC
- ▶ Interpretación de coeficientes:
 - ▶ Coeficiente positivo $\rightarrow$ aumenta probabilidad del evento ($Y=1$)
 - ▶ Coeficiente negativo $\rightarrow$ disminuye probabilidad del evento

Introducción

- ▶ Dataset: 569 muestras con 32 características de tumores mamarios.
- ▶ Objetivo: Predecir si un tumor es benigno (0) o maligno (1) usando regresión logística.
- ▶ Variables clave: radius, perimeter, area, concavity, texture, etc.

Distribución de Diagnóstico




Figure: Distribución de tumores benignos y malignos.

Histogramas de Variables Numéricas




Figure: Histogramas de todas las variables numéricas.

Boxplots Clásicos




Figure: Diagrama de caja de radius_mean según diagnóstico.

Boxplots Logarítmicos




Figure: Boxplot logarítmico de radius_mean según diagnóstico.

Matriz de Correlación




Figure: Matriz de correlación entre todas las variables.

Modelo de Regresión Logística

- ▶ **Precisión:** 97.37% → 97 de cada 100 predicciones correctas.
- ▶ **Matriz de Confusión:** $\begin{bmatrix} 70 & 1 \\ 2 & 41 \end{bmatrix}$
 - ▶ 70 benignos correctamente clasificados
 - ▶ 41 malignos correctamente clasificados
 - ▶ Solo 3 errores en 114 muestras
- ▶ **Reporte de clasificación:**
 - ▶ Clase 0 (benigno): precision 0.97, recall 0.99, F1 0.98
 - ▶ Clase 1 (maligno): precision 0.98, recall 0.95, F1 0.96
- ▶ **Variables más importantes:** area_worst, texture_worst, concave points_mean, symmetry_worst, perimeter_worst

Variables más importantes del modelo

Variable	Coeficiente
area_worst	1.471442
texture_worst	1.299777
concave points_mean	1.224912
symmetry_worst	1.149765
perimeter_worst	1.115476
concavity_mean	1.101253
perimeter_se	0.858178
radius_se	0.806596
area_mean	0.804358
concave points_worst	0.791304

Table: Top 10 variables más importantes según los coeficientes del modelo.

Interpretación de Coeficientes

- ▶ Coeficientes positivos $\rightarrow$ aumentan la probabilidad de malignidad ($\text{diagnosis} = 1$).
- ▶ Mayor valor absoluto $\rightarrow$ la variable tiene más influencia en la predicción.
- ▶ Ejemplo:
 - ▶ `area_worst` tiene coeficiente 1.471 $\rightarrow$ incrementa significativamente la probabilidad de malignidad.
 - ▶ `concave points_mean` y `texture_worst` también son muy importantes.
- ▶ En general, las variables relacionadas con tamaño y forma (`area`, `perimeter`, `concavity`) son las más predictivas.

Interpretación de Odds Ratio

- ▶ Coeficiente $\beta = 1.471$ no se interpreta como porcentaje.
- ▶ La probabilidad predicha se calcula así:

$$P(Y = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_n X_n)}}$$

- ▶ Log-odds:

$$\text{log-odds} = \ln \left(\frac{P}{1 - P} \right)$$

- ▶ Odds ratio:

$$OR = e^{1.471} \approx 4.35$$

- ▶ Esto significa que un aumento de 1 unidad en `area_worst` multiplica por 4.35 las probabilidades de malignidad frente a benignidad.

Probabilidades Predichas




Figure: Probabilidades predichas de malignidad según el modelo.

- Cada punto representa una muestra del conjunto de prueba.
- Color indica clase real: 0 = benigno, 1 = maligno.

Probabilidades Predichas

- ▶ Cada punto representa una muestra del conjunto de prueba.
- ▶ Color indica clase real: 0 = benigno, 1 = maligno.
- ▶ Permite visualizar qué tan bien separa el modelo las dos clases.

Curva ROC y AUC




Figure: Curva ROC del modelo de regresión logística. $AUC = 0.998$

Curva ROC y AUC

- ▶ Muestra la relación entre la **tasa de verdaderos positivos (TPR)** y la **tasa de falsos positivos (FPR)** para diferentes umbrales.
- ▶ $AUC = 0.998 \rightarrow$ desempeño excelente del modelo para distinguir benignos y malignos.
- ▶ Puntos cercanos al vértice superior izquierdo indican alta sensibilidad y baja tasa de falsos positivos.

Conclusiones

- ▶ El modelo tiene alta precisión y capacidad discriminativa.
- ▶ Las variables más importantes están relacionadas con tamaño y forma del tumor.
- ▶ Probabilidades predichas y ROC muestran clara separación entre benignos y malignos.
- ▶ La regresión logística es un modelo confiable para este tipo de clasificación.